

StoryScope视角下的AI小说系统研究与落地方案

执行摘要

如果你的目标是**既做出可用产品，又把工作组织成偏学术、可冲 CCF-A 的论文**，最优路线不是单纯做“AI写作助手”，而是把问题定义成：**如何在中文长篇/中篇小说生成中，用显式叙事状态、检索约束与反思修订机制，降低 AI 小说的可检测叙事“指纹”，同时提升长程一致性、风格稳定性与用户偏好**。这一定义直接对接了近期研究中的两个关键结论：其一，StoryScope 证明 AI 小说与人类小说的差异不只在表层文风，更体现在角色能动性、时间复杂度、主题阐释方式、情节分叉结构等**话语层叙事特征**上；其二，Lost in Stories 与 ConStory-Bench 说明长篇叙事的一致性 bug 仍是主流 LLM 的系统性短板；其三，R2-Write 进一步指出，通用“推理模型”在开放式写作上收益有限，必须显式引入**反思与修订模式**。这意味着，能发论文的创新点，应落在**显式叙事规划 + 状态约束 + 自动化诊断**，而不是只换一个更强底模。 ¹

从工程落地看，在你当前信息不完整的前提下，最稳妥的方案是采用**双层架构**：上层以 Flowith 作为知识工作台、实验编排与人机协作界面，下层以 Manus API 作为异步任务执行、评测代理与批处理器；核心生成系统使用“**规划器—状态管理器—检索器—起草器—修订器—评测器**”流水线，其中状态管理器维护 world bible、人物卡、场景约束、伏笔回收表和风格包，检索器从你自建的知识库与样例库中做分层召回，修订器专门消减 StoryScope 所揭示的 AI 叙事异质性，例如“过度解释主题”“单轨平整剧情”“外部视角人物描写偏置”等。Flowith 官方公开页面显示其定位是 **agentic workspace**，包含 Canvas、Knowledge Garden、FlowithOS 与 Agent Neo 等组件；Manus 官方文档则提供了比较清楚的 REST API、任务、文件、Webhook、Agent 与多轮消息接口，这非常适合把它们放在“编排层”而不是“核心模型层”。 ²

从学术产出看，我建议把工作拆成一个“**论文主线**”和一个“**产品副线**”。论文主线建议题目方向为：**面向中文长篇小说生成的显式叙事状态控制与 StoryScope 风格诊断框架**。产品副线则是一个四到六周可交付的 MVP：输入题材、人设、世界观和样例风格，系统自动输出故事大纲、章节分解、场景草稿、修订稿与一致性报告。对于会议定位，如果你突出的是**中文叙事 benchmark + 可控生成框架 + 系统评测与人类偏好实验**，最对口的是 ACL；如果更强调**Agent orchestration、工具使用与系统闭环**，AAAI / IJCAI 也是合理选项。它们都在 CCF 人工智能 A 类会议名单中。 ³

工程上，第一阶段不建议一开始就训练大模型本体。更可执行的路线是：先用**API 模型做强基线**，同时用 7B–32B 开源模型做**私有化草拟器/风格适配器**。原因很简单：LoRA/QLoRA 已经证明参数高效微调能显著降低微调成本，QLoRA 甚至在论文设置中把 65B 微调压缩到单张 48GB GPU 可做；而 vLLM 与 SGLang 都已经提供了 OpenAI 兼容服务、缓存和多 GPU 推理能力，足以支撑 7B–32B 级别的实验链路。MVP 阶段的资源重点不在“堆卡”，而在“**把数据结构和自动评测先做对**”。 ⁴

未指定项与工作假设

你给出的需求里，有几项关键信息没有明确。为了给出可执行方案，我必须先把这些假设写清楚，否则后续的资源与架构建议会失真。

未指定项	本报告采用的假设	对方案的影响
Flowith 的“无线资源”具体含义	视为 Flowith 账号/团队空间 + FlowithOS/Agent Neo 额度 + Knowledge Garden 存储 + 网络化 agent 工作台能力 ，不把它当作底层 GPU 云平台	Flowith 作为 编排、知识管理与人机协同层 ，而不是模型训练底座

未指定项	本报告采用的假设	对方案的影响
Flowith 是否有公开 API	公开页面主要展示 Canvas、Knowledge Garden、FlowithOS、Agent Neo 与定价/额度；本报告 不假定存在稳定公开开发者 API ，只建议做“适配层”并预留 MCP / Webhook / 文件交换接口	降低对单一平台接口的耦合，避免论文与系统都被平台变动绑死 ⁵
Manus 的含义	以 Manus API / AI agent 平台 为主假设，因为其官方文档明确提供 REST API、Task、Agent、Files 与 Webhooks	Manus 作为 任务执行器、评测 runner、异步研究员与批处理代理 最合适；如果你说的 Manus 实际是手写设备，则只需替换输入层 ⁶
可用模型	假设你可以使用 闭源 API 模型与开源可部署模型 两类资源	因此方案设计成“模型路由器”而不是绑定某一家模型
预算	未给出；本报告分别给出 API-first MVP 与 轻量自托管 MVP 两档	便于你按经费和投稿节奏切换
目标用户群	默认是 中文创作者、互动小说作者、轻量工作室与研究实验参与者	所以优先考虑中文能力、风格控制、长上下文与一致性，而不是代码生成第一
版权数据来源	默认你愿意优先使用 公版/授权/自有样例 ，不把来源不明的版权小说直接用于训练	这会影响学术伦理、产品上线与后续论文可复现性

这组假设与公开材料是相容的：Flowith 对外强调的是工作台、知识系统、长上下文 agent 与配额体系；Manus 对外强调的是可编排 Agent API、任务与文件生命周期；因此，把 Flowith 放在 **workflow 上层**、把 Manus 放在 **执行与实验层**，是当前信息下最稳妥的架构假设。 ⁷

StoryScope的研究启发与面向 CCF-A 的问题定义

StoryScope 最重要的启发，不是“AI 小说可以被检测”，而是**AI 小说有可解释的叙事偏置**。该工作在 10,272 个 prompt、61,608 篇约 5,000 词的故事上，构造了覆盖 10 个维度、304 个话语级叙事特征的特征空间；仅用叙事特征，就能达到人类 vs. AI 检测 93.2% macro-F1、六路作者归因 68.4% macro-F1。论文进一步指出，AI 小说更容易**过度解释主题、偏好整洁的单轨情节**，而人类小说则更具**道德模糊性与时间复杂度**；不同模型还呈现了不同“叙事指纹”，例如 Claude 更容易出现平坦的事件升级、GPT 更容易过度使用梦境段落、Gemini 更偏向外部刻画人物。 ⁸

这恰好给你的系统设计提供了一个**论文级目标函数**：不要用“写得更像人类”这种空泛说法，而要把目标落成**可测量的叙事分布修正问题**。学术上可以定义为：

“给定风格、人设与大纲约束，是否可以通过显式叙事状态建模、检索增强与反思修订，显著减少生成文本在 StoryScope 特征空间中的 AI 偏置，并在长篇一致性与用户偏好上实现提升？”这个问题兼具**新颖性、可实验性、可自动评测性与可产品化性**。 ⁹

另一个重要背景是，近期关于 AI 写作“怪癖”的研究并不只看到叙事问题，也观察到了**编辑层面的统一病灶**。LAMP 的相关工作在 GPT-4o、Claude 3.5 Sonnet 和 Llama-3.1 上分析写作编辑，识别出 7 类不受欢迎的编辑习惯，并表明许多问题存在于不同模型之间。这说明你若只做 prompt 调整，通常只能缓解局部问题；更有效的做法，是把“异常叙事/异常编辑”设计成**独立可学习的评测器与修订器**。 ¹⁰

如果你偏向 CCF-A 论文，我建议主问题收敛为下面这个更锋利的版本：

论文命题	学术价值	产品价值	会议适配
StoryScope-CN : 中文小说叙事特征空间与 AI 叙事指纹基准	数据集/评测贡献强, 易做成 benchmark paper	可沉淀成自动诊断模块	ACL、AAAI
State-Write : 显式叙事状态控制的长篇小说生成框架	方法贡献最强, 适合做 ablation	直接转化为生成引擎	ACL、IJCAI、AAAI
Reflective Fiction Agent : 反思修订 + 工具检索的小说生成 agent	系统贡献强, 适合结合 Flowith/Manus	最利于做 demo 与 MVP	AAAI、IJCAI、ACL Findings

在这三条里, 我最推荐第二条, 也就是“**显式叙事状态控制**”。因为 Plan-and-Write、Hierarchical Neural Story Generation、Fabula 与 StoryState 这一系列研究都在提示: 故事质量不是靠一次性长文本采样得到的, 而是依赖**分层计划、场景/beat 结构、角色/世界状态显式化**。换句话说, 真正更像“作家工作流”的系统, 才更可能同时赢得论文与产品。 ¹¹

现有技术 & 模型能力清单与评估

从今天可获得的模型生态看, 你需要的不是“最强单模型”, 而是**写作系统里的角色分工**。闭源 API 模型适合做**高质量规划、修订与判别**; 开源可部署模型适合做**草稿扩写、私有部署与实验复现**; 嵌入/重排模型则为 RAG 和风格召回服务。官方资料显示, GPT-4.1 具有 1,047,576 token 上下文, 突出指令遵循与工具调用; Claude Sonnet 4.6 的 API 已提供 1M token context beta; Gemini 2.5 Pro 支持 1,048,576 输入 token、65,536 输出 token, 并支持结构化输出、函数调用、代码执行与文件搜索; DeepSeek-V4-Flash / Pro 支持 1M context、最高 384K 输出; GLM-5.1 提供 200K 上下文、128K 最大输出, 并在官方文档中把“**创意写作**”列为推荐场景; Qwen3 公开了从 0.6B 到 235B-A22B 的开源模型, 主力版本上下文为 128K, 且采用 Apache 2.0 许可; DeepSeek-V3 作为公开技术报告模型, 采用 671B total / 37B active 的 MoE 结构。 ¹²

模型选型表

模型	公开能力要点	更适合在小说系统中承担的角色	主要优点	主要风险
GPT-4.1	1M context, 指令遵循与工具调用强, API 价格公开 ¹³	高质量规划器、修订器、论文写作 judge	稳、长上下文、工具调用好	成本高于 DeepSeek / GLM
Claude Sonnet 4.6	1M context beta, 面向 coding/agent/long-context 升级, \$3/\$15 每百万 token 起 ¹⁴	长文修订、角色一致性 review、复杂 agent 子任务	长任务处理和 agent workflow 强	写作成本偏高
Gemini 2.5 Pro	1,048,576 输入、65,536 输出, 支持结构化输出、函数调用、代码执行、文件搜索 ¹⁵	规划器、结构化 scene planner、自动评测 judge	多工具、长上下文、价格中位	中文文风需额外校准
DeepSeek-V4-Flash / Pro	1M context, 最高 384K 输出, OpenAI/Anthropic 兼容 API; 价格极低 ¹⁶	大批量草拟、候选采样、实验扩展	性价比极高, 适合批量实验	论文中若用作唯一强模型, 审稿人可能质疑上限

模型	公开能力要点	更适合在小说系统中承担的角色	主要优点	主要风险
GLM-5.1	200K context、128K 输出，官方推荐创意写作与长程任务 ¹⁷	中文写作主力修订器、国内部署方案	中文环境友好、价格透明	国际审稿讨论时需补充泛化实验
Qwen3-14B / 32B / 235B-A22B	开源，128K context，Apache 2.0 ¹⁸	自托管草拟器、风格适配器、可复现实验底模	开源可控，适合 LoRA	纯 base 使用时长篇一致性仍需系统补强
DeepSeek-V3	671B total / 37B active，14.8T 训练 token ¹⁹	大规模开源 baseline、研究复现实验	强开源基线	本地部署门槛很高

对你的目标而言，**推荐的基础组合**是：

场景	推荐组合
最快做 MVP	DeepSeek-V4-Flash 负责草拟 + GPT-4.1 / Gemini 2.5 Pro 负责规划和修订
偏中文产品化	GLM-5.1 负责规划与修订 + Qwen3-14B/32B 自托管草拟
偏论文可复现	Qwen3-32B 或 14B 做主模型 + 少量闭源模型作 upper bound
偏低成本大实验	DeepSeek-V4-Flash 大量跑 batch + 少量 Sonnet / GPT 做 judge

RAG 侧建议优先选**多语种嵌入 + 重排**路线。BGE-M3 支持 100+ 语言、支持长文档到 8192 token，并同时支持 dense / sparse / multi-vector 检索；Qwen3 Embedding 官方也已发布面向检索与 reranking 的系列模型。对中文小说系统而言，这类模型比通用句向量更适合做“人物卡—设定集—伏笔表—风格样例”四类异构知识的混合检索。 ²⁰

叙事、风格与人设生成的方法比较

从研究与工程两条线同时看，**不存在单一方法可以解决AI小说的全部问题**。Prompt 适合做冷启动，LoRA/SFT 适合做稳定风格与角色响应，RLHF/DPO 更适合把“偏好”显式注入，控制码/模板适合可解释控制，RAG 适合把世界知识与人物记忆外置，混合神经符号方法则最适合长篇叙事的一致性与因果可控。近期的 R2-Write 还表明，开放式写作要显式做“反思—修订”回路，否则通用 reasoning 模型的收益很有限。 ²¹

方法对比表

方法	代表思想/来源	适合解决的问题	优势	劣势	适用场景
Prompt 工程	指令、few-shot、角色设定、分阶段 prompting；现代大模型普遍支持长上下文和工具调用 ²²	冷启动、无训练原型、少样本风格模仿	成本低、迭代快	稳定性差，长篇漂移严重	MVP 起步、ablation baseline
SFT / LoRA	LoRA、QLoRA ²³	风格包、人设响应、章回模板稳定化	参数高效、可复现	需要较干净数据与训练流程	专属风格、品牌化写作

方法	代表思想/来源	适合解决的问题	优势	劣势	适用场景
RLHF	InstructGPT 路线 ²⁴	提升主观偏好、降低不受欢迎输出	能学到“用户喜欢什么”	成本高、实现复杂	大团队/论文强化版
DPO / 偏好优化	Direct Preference Optimization ²⁵	用 pairwise preference 学“更像作家/更稳的人设”	比 PPO 式 RLHF 简洁稳定	依赖偏好数据质量	中期研究主线，强烈推荐
控制生成	CTRL 控制码、PPLM、slot/template ²⁶	题材、视角、叙事节拍、禁忌约束	可解释性强，便于 UI 暴露	表达上限受限，容易模板味	商业产品、可控互动小说
RAG	RAG、FLARE 等主动检索 ²⁷	世界观一致性、人物记忆、伏笔回收、写作样例召回	更新方便、可审计、可引用来源	检索噪声会污染生成	长篇小说、连载系统
混合神经符号	显式 plot/state graph、心理状态链、结构化 story state ²⁸	因果一致、人物动机、章节间状态延续	最适合长篇叙事	工程复杂度最高	论文主创新、精品路线
反思修订	writer-judge-revise, R2-Write 风格 ²⁹	去除 AI 腔、修复逻辑漏洞、补伏笔	对开放式写作特别有效	延迟增加	高质量最终稿

最推荐的组合


真正适合你当前目标的，不是单一方法，而是下面这条**组合拳**：

显式叙事状态 + RAG + 写作/判别双模型 + 轻量 LoRA + 反思修订

原因很明确。StoryScope 告诉我们“AI 在叙事层有偏置”；ConStory 告诉我们“长篇会出现一致性 bug”；R2-Write 告诉我们“写作需要显式修订回路”；Plan-and-Write / Fabula / StoryState 告诉我们“如果不把 story plan 暴露成结构，长篇控制几乎无从谈起”。因此，最优系统应当是：先规划，再检索，再草拟，再诊断，再修订，而不是让一个模型从设定一路写到终稿。 ³⁰

基于 Flowith 与 Manus 的系统架构与数据流

在当前假设下，我建议把 Flowith、Manus 与模型系统分成三层：**协作层**、**编排层**、**生成层**。协作层由 Flowith 承担，负责 Canvas 上的大纲协同、Knowledge Garden 中的设定库与样例库管理，以及实验结果回看；编排层由你的自建 Orchestrator 与 Manus API 共同承担，负责任务触发、异步执行、批量评测、报告回传；生成层则由模型路由器、检索器、状态管理器和自定义评测器组成。这样做的核心好处是：即使未来要把 Flowith 或 Manus 替换掉，**论文里的方法层不会受损**。 ³¹



数据流说明

生成一次章节时，数据流应当是：

创作者先在 Flowith 中定义题材、世界观、人设、目标篇幅与样例风格；Orchestrator 读取这些输入后，在 State Manager 中生成一份 **story bible**，包括角色表、世界规则、剧情主线、章节目标与未回收伏笔；Retriever 对 story bible、历史章节与风格样例做分层检索；Planner 输出 scene plan 或 beat list；Draft Generator 按章节计划生成候选文本；StoryScope 风格诊断器与一致性检查器给出结构性反馈；Reviser 根据反馈改写，最终把章节、诊断分数和修订日志回写到 Flowith。Manus 在这个循环中最适合做异步实验代理，例如批量跑多模型对比、自动收集评价、生成实验报告。 ³²

推荐的数据结构

先把“故事状态”定义清楚，比任何模型选择都重要。建议统一成下面的 JSON。

```
{
  "story_id": "novel_cn_001",
  "meta": {
    "language": "zh-CN",
    "genre": ["悬疑", "都市奇幻"],
    "target_length_words": 80000,
    "narrative_pov": "limited_third_person"
  },
  "world_bible": {
    "setting": "近未来上海与潜流世界并存",
    "rules": [
      "潜流生物不可在公开摄像头下显形",

```



```
{
  "job_type": "draft_chapter",
  "story_id": "novel_cn_001",
  "chapter_id": "ch_07",
  "inputs": {
    "story_state_ref": "kg://novel_cn_001/state/ch_07.json",
    "style_pack_ref": "kg://styles/noir_urban_pack",
    "retrieval_budget": 12,
    "draft_model_profile": "cheap-drafter",
    "revise_model_profile": "strong-reviser"
  },
  "callbacks": {
    "on_complete": "https://your-domain.example/api/flowwith/callback",
    "on_report": "https://your-domain.example/api/flowwith/report"
  }
}
```

Manus 侧就清晰得多。官方文档给出了基于 `https://api.manus.ai` 的 v2 API，支持任务、多轮消息、文件、Agent 和 Webhook；公开示例还展示了 `task.sendMessage` 与 `task.listMessages` 的使用方式。对于你的系统，我建议 Manus 只做三件事：**批量实验 runner**、**自动评测代理**、**研究资料与报告生成器**。不要把“单章实时写作”也交给 Manus，否则延迟和可控性会变差。 ³⁵

```
curl -X POST https://api.manus.ai/v2/task.sendMessage \
-H "Content-Type: application/json" \
-H "x-manus-api-key: $MANUS_API_KEY" \
-d '{
  "task_id": "agent-default-main_task",
  "message": {
    "content": "请对 novel_cn_001 的 ch_07 运行一致性检查，输出 JSON 报告。"
  }
}'
```

关键模块伪代码

RAG 集成伪代码

```
def retrieve_story_context(query_state, vector_db, topk=12):
    """
    分层召回：
    1. 人物设定
    2. 世界规则
    3. 历史章节摘要
    4. 风格样例
    """
    q_char = build_query(query_state, kind="character")
    q_world = build_query(query_state, kind="world")
    q_hist = build_query(query_state, kind="history")
    q_style = build_query(query_state, kind="style")
```



```

hits = []
hits += vector_db.search(namespace="characters", query=q_char, topk=3)
hits += vector_db.search(namespace="world_bible", query=q_world, topk=3)
hits += vector_db.search(namespace="chapter_summaries", query=q_hist, topk=4)
hits += vector_db.search(namespace="style_pack", query=q_style, topk=2)

# 规则过滤：去除与当前 POV、时间线冲突的片段
hits = filter_conflicts(hits, query_state)

# 重排：优先保留人物/伏笔/章节目标强相关片段
ranked = rerank(hits, query_state)
return ranked[:topk]

```

推理服务 API 伪代码

```

from fastapi import FastAPI
from pydantic import BaseModel

app = FastAPI()

class DraftRequest(BaseModel):
    story_state: dict
    user_instruction: str
    mode: str = "draft" # plan / draft / revise

@app.post("/v1/story/generate")
def generate(req: DraftRequest):
    ctx = retrieve_story_context(req.story_state, vector_db)
    plan = planner_model.run(req.story_state, ctx, req.user_instruction)

    if req.mode == "plan":
        return {"plan": plan}

    draft = drafter_model.run(plan, ctx, req.story_state)

    issues = []
    issues += storyscope_checker.analyze(draft, req.story_state)
    issues += consistency_checker.analyze(draft, req.story_state)

    final_text = reviser_model.run(
        draft=draft,
        issues=issues,
        plan=plan,
        context=ctx,
        rules=req.story_state["world_bible"]["rules"]
    )

    return {
        "plan": plan,

```

```

"draft": draft,
"issues": issues,
"final_text": final_text
}

```

训练、微调、在线推理与 MVP 资源成本

第一原则很简单：**先做系统，后做模型**。对于 AI 小说这种高主观度任务，论文真正稀缺的是“叙事结构控制与评测框架”，而不是再做一个泛化预训练模型。LoRA 证明可以用极少可训练参数适配大模型；QLoRA 则进一步把量化与 LoRA 结合起来，大幅降低显存需求。对你而言，微调的主要对象应是**风格适配器、角色响应器、修订器**，而不是整模型。 ²³

训练与微调建议

训练数据建议分成四层：

数据层	内容	来源建议	用途
结构层	大纲、scene plan、beat、人物关系、伏笔表	你自建或半自动标注	训练 planner
表达层	成稿章节、风格样例、改写对	公版/授权/自有文本	训练 drafter / style adapter
偏好层	A/B 版本、人工偏好、编辑反馈	内部写作者或众包评测	DPO / preference optimization
诊断层	一致性错误、StoryScope 风格偏差标签	自动预标 + 人工校正	训练 reviser / checker

最小可行训练方案如下：

阶段一：SFT / LoRA

选一个 7B–14B 或 14B–32B 的开源中文/多语模型，训练两类 adapter：

其一是 `style_lora`，学习文体、句法、叙述视角；

其二是 `revise_lora`，学习从“草稿 + 诊断报告”到“修订稿”的映射。

这个阶段最容易起量，也最容易写清楚 ablation。 ²³

阶段二：DPO / 偏好优化

把同一章的多个候选版本做 pairwise 偏好数据，偏好维度包含：叙事连贯性、风格一致性、人物不崩、伏笔回收自然度、主观可读性。DPO 的优势是实现相对简单，且比 PPO 式 RLHF 更适合你这种中小团队。 ³⁶

阶段三：反思修订蒸馏

参考 R2-Write 的启发，把“writer-judge-revise”的高质量痕迹蒸馏给一个更小的修订模型。这样线上最终可以用一个轻量 reviser 完成大部分修改，只在疑难 case 上调用强模型。 ³⁷

微调代码示例

```
from transformers import AutoModelForCausalLM, AutoTokenizer
from peft import LoraConfig, get_peft_model
from trl import SFTTrainer, SFTConfig

base_model = "Qwen/Qwen3-14B" # 示例, 可替换为你实际选择的开源模型
tokenizer = AutoTokenizer.from_pretrained(base_model, trust_remote_code=True)
model = AutoModelForCausalLM.from_pretrained(
    base_model,
    trust_remote_code=True,
    device_map="auto",
    load_in_4bit=True # QLoRA 风格
)

lora_cfg = LoraConfig(
    r=16,
    lora_alpha=32,
    lora_dropout=0.05,
    target_modules=["q_proj", "k_proj", "v_proj", "o_proj"]
)
model = get_peft_model(model, lora_cfg)

train_cfg = SFTConfig(
    output_dir="./outputs/style_lora",
    per_device_train_batch_size=1,
    gradient_accumulation_steps=16,
    learning_rate=2e-4,
    num_train_epochs=2,
    max_seq_length=4096,
    logging_steps=20,
    save_steps=200
)

trainer = SFTTrainer(
    model=model,
    train_dataset=style_dataset, # 输入格式: instruction / input / output
    args=train_cfg
)
trainer.train()
trainer.model.save_pretrained("./outputs/style_lora/final")
```

推理资源估算

MVP 级资源不需要大集群。更现实的划分是：

组件	推荐配置	说明
Embedding / Rerank	1 张 24GB 卡或 1×L4 级云 GPU	足够支持小说知识库检索与重排

组件	推荐配置	说明
开源草拟模型	7B–14B 4bit 可在 24GB–48GB 显存区间运行；32B 通常需要 48GB–80GB 级显存更稳	适合做便宜草稿与可复现实验
强模型修订	直接走 API	省去本地大模型集群成本
存储	PostgreSQL + 对象存储 + 向量库，起步 100GB 即可	重点存 scene state、样例库与日志
带宽	内网/云区内为主；对外只需普通 API 出口	小说生成主要瓶颈不是带宽，而是 token 生成与评测链路

推理框架方面，vLLM 与 SGLang 都提供 OpenAI 兼容接口，便于把开源模型接入一个统一的 model router；SGLang 还强调低延迟、高吞吐和多 GPU 并行。对于论文和工程，这一点非常关键，因为你可以在同一 API 规范下切换“自托管”和“外部 API”。³⁸

成本估算

API-first MVP

以下示例假设：
 月内 3,000 次生成会话；每次平均 **12k 输入 + 4k 输出 token**；无长上下文溢价；只计算主模型 token 成本，不含工具/检索附加费用。官方价格来自各自文档，月成本由此计算。³⁹

模型	官方价格	该负载下月成本
GPT-4.1	输入 \$2 / MTok，输出 \$8 / MTok ⁴⁰	\$168 / 月
Claude Sonnet 4.6	输入 \$3 / MTok，输出 \$15 / MTok 起 ⁴¹	\$288 / 月
Gemini 2.5 Pro	≤200k prompt 输入 \$1.25 / MTok，输出 \$10 / MTok ⁴²	\$165 / 月
DeepSeek-V4-Pro	输入 \$0.435 / MTok，输出 \$0.87 / MTok ⁴³	约 \$26.1 / 月
GLM-5.1	输入 6 元 / MTok，输出 24 元 / MTok (≤32k 输入档) ⁴⁴	约 504 元 / 月

这张表给出的结论很明确：**如果你在做大规模实验，DeepSeek-V4-Pro / Flash 与 GLM-5.1 的性价比非常适合跑批；如果你在做最终版本修订或论文中的 upper bound，对照 GPT-4.1 / Sonnet / Gemini 更有说服力。**⁴⁵

轻量自托管 MVP

如果你想减少 API 依赖，建议用“**自托管草拟 + API 修订**”的混合策略。公开云上，Google Cloud 文档给出了 L4 约每小时 \$0.56004024 的 GPU 价格；AWS 的 Capacity Blocks for ML 页面则给出了 H200 级加速器约每 GPU 每小时 \$4.975 的示例有效小时价。虽然这两类价格不是一一可比的同规格现货价，但足以说明 7B–14B 级轻量推理与 70B+ 级大模型托管之间存在明显成本带宽。你的 MVP 没必要一开始就站到 H100/H200 档。⁴⁶

优化策略

量化方面，AWQ 与 GPTQ 都是成熟路线。AWQ 通过保护少量重要通道实现低比特压缩；GPTQ 则是大模型后训练量化的经典方法，论文报告在 3–4 bit 下可以显著压缩模型并保持较高精度。训练侧用 QLoRA，推理侧用 AWQ/GPTQ，是目前最均衡的选择。⁴⁷

蒸馏方面，不建议蒸馏“最终小说输出”，而建议蒸馏**中间能力**：比如“scene planner”“consistency reviser”“style classifier”。这样蒸馏目标更稳定，也更容易在论文里说明为什么有效。分布式推理方面，MVP 不一定需要；如果后续发展成连载平台，再使用 SGLang / vLLM 的 prefix caching、批处理和多 GPU 并行即可。

第一阶段最小可行产品

我建议你的第一阶段 MVP 定义为：


- 输入**：题材、篇幅、世界观、人设、3-5 段风格样例
- 输出**：故事大纲、10-20 个 scene plan、第一章草稿、修订稿、一致性报告、风格诊断报告
- 必须具备**：
 - Flowith 端可管理 story bible；
 - Manus 端可跑评测任务并回传 JSON 报告；
 - 模型侧具备规划—草拟—修订三级流水线；
 - 自动评测至少包括：人物一致性、伏笔回收、时间线冲突、StoryScope 偏置指标。

- 时间估算**：4-6 周。
- 人力配置**：1 名全栈/后端工程师 + 1 名 NLP/ML 工程师 + 1 名兼职编辑/标注者。
- 推荐资源**：1×24GB 或 1×48GB GPU + 常规云数据库存储；若完全 API-first，甚至可以先不买训练卡。
- 学术收益**：到第 4 周时，你就应当已经拥有一个可投稿雏形：系统方法、日志、自动评测器和初步对比实验。

开发计划、评测、合规与风险

里程碑与甘特图

下面的节奏既考虑了产品实现，也考虑了论文素材沉淀。



这个计划的关键在于：**MVP 与论文素材同步产生**。你不应该先做完产品再去想论文，而应该在日志、状态结构、自动评测器设计之初就按照论文标准保存实验痕迹。近期系统研究已经反复证明，单纯 demo 很难说服学术审稿人；但如果你从一开始就有过程日志、可复现配置与自动评测，就能把工程工作自然转成 paper artifact。

评估指标与自动化评测

评测不能只看 BLEU、ROUGE 这类传统指标。对于小说生成，更合理的指标体系应当分成五类。

指标	具体定义	自动化方法
叙事连贯性	章节内事件因果闭环、scene 转换自然度	使用 state transition 校验 + judge 模型 pairwise 比较

指标	具体定义	自动化方法
风格一致性	叙述视角、句法节奏、语气与样例风格的一致度	style encoder 相似度 + authorship classifier
多样性	不同采样版本的语义/结构差异，避免模板化	MAUVE、distinct-n、story feature dispersion 52
可控性	是否满足题材、POV、人设、设定与禁忌约束	rule pass rate + slot fill accuracy
用户满意度	写作者是否愿意继续使用该版本	盲测 A/B、5 分量表、best-worst ranking

自动化评测方面，我建议直接实现两个自定义模块：

其一是**StoryScope-style Narratology Checker**，不必一开始复现全部 304 特征，但至少先做“过度主题解释”“单轨情节”“人物内外视角失衡”“时间断裂不足/过度”“事件升级曲线平直”等核心指标；

其二是**ConStory-style Consistency Checker**，覆盖人物事实、时间线、设定规则、道具状态与章节前后矛盾。这样做的好处是，你的评测器本身也能成为论文的一部分。⁵³

如果你需要“有参考答案”的局部任务，比如对已有大纲的章节实现、对已有草稿的风格改写，可以再辅以 BERTScore 等语义相似指标；但在开放式写作主任务上，分布型指标与人类偏好评测更重要。⁵⁴

部署、迭代与用户测试

部署建议采用三环境：**research / staging / production-lite**。Research 环境跑多模型对比与批量生成；staging 环境接入 Flowith / Manus 做半自动测试；production-lite 环境只保留最稳定的 1-2 条生成链路。所有生成步骤都保留 `story_state`、检索命中、模型版本、采样参数与修订日志，这样无论是做论文复现实验，还是做线上问题追踪，都有依据。由 Manus 负责异步批量实验与报告归档会非常顺手，因为它原生支持任务、多轮消息、文件和 Webhook；而在模型服务这一层，vLLM / SGLang 的 OpenAI 兼容接口能显著降低服务切换成本。⁵⁵

用户测试不应只找普通读者，还应该至少包括两类人：**有持续写作经验的创作者与研究型评估者**。前者能指出“像不像作者工作流”，后者能指出“可不可以做成论文证据”。近期 Fabula 的经验也说明，写作者更愿意接受能暴露详细故事计划、支持局部重写与多轮迭代的系统，而不是黑箱式一键出稿。⁵⁶

版权与伦理合规

如果你准备把系统真正用于连载、商业化或论文公开，版权与标识问题不能后置。中国网信办等四部门发布的《人工智能生成合成内容标识办法》已于 **2025 年 9 月 1 日** 起施行，明确要求对 AI 生成合成内容进行标识；美国版权局关于 Copyright and Artificial Intelligence 的官方报告则强调，纯 AI 生成内容本身不获得版权保护，而人类作者对作品的可识别原创性贡献仍可受保护，是否构成作者性需要个案分析。对你来说，最稳妥的流程是：

训练数据优先公版/授权/自有；

输出作品默认保留“AI 辅助生成/修订”元数据；

编辑日志保留人类修改痕迹；

若投稿论文，正文与附录明确说明数据来源、模型角色与人工参与比例。⁵⁷

风险与替代方案

风险	影响	替代方案
Flowith 程序化接入能力不明确	平台耦合风险	把 Flowith 仅作工作台，核心状态与任务全在自建后端
Manus 配额/延迟不稳	批量评测受影响	Manus 仅跑异步实验，实时链路由自建 worker 执行
仅靠 prompt，长篇依旧崩角色	论文与产品都不稳	尽快把 story_state + RAG + reviser 上线
只做工具集成，创新性不足	难发 CCF-A	必须补 benchmark、自动评测器、消融、人类偏好实验
版权数据不干净	上线与投稿风险	只用公版/授权，自建 style pack，以编辑日志证明人类贡献
成本失控	无法持续迭代	采用“便宜草拟 + 强模型修订”的混合路由

开放问题与局限

这份方案仍有几项依赖你的后续确认。最重要的是：
你手里的 Flowith 究竟是普通账号、团队版还是企业接口；
Manus 是否就是 Manus API，而不是别的 Manus 工具；
你能接受多大比例的闭源 API 参与；
你是更想做**小说生产工具**，还是更想做**投稿级 benchmark 与方法论文**。这些信息会影响最终是否押注 ACL 主会级别的方法论文，还是先做一个更强的 system/demo 路线。当前报告已经按“信息不完整但要能立即开工”的原则，给出了不依赖这些答案也能推进的保守方案。 58

主要参考来源

以下来源是本报告最关键、最“承重”的依据，优先使用了官方文档、原始论文与中文官方材料：

类别	主要来源
核心研究问题	StoryScope; Lost in Stories / ConStory-Bench; R2-Write; Plan-and-Write; Hierarchical Neural Story Generation; StoryState; Fabula 59
模型与平台	OpenAI GPT-4.1 官方模型页; Anthropic Sonnet 4.6 官方页; Gemini 2.5 Pro 官方模型与定价页; DeepSeek 官方 API 文档; 智谱 GLM-5.1 中文官方文档; Qwen3 官方博客; Flowith 官方产品页与价格页; Manus 官方 API 文档 60
方法学	LoRA; QLoRA; InstructGPT / RLHF; DPO; CTRL; PPLM; RAG; FLARE; AWQ; GPTQ; Distilling Step-by-Step; vLLM; SGLang 61
合规与投稿	CCF 人工智能 A 类会议列表; 中国《人工智能生成合成内容标识办法》; 美国版权局 Copyright and Artificial Intelligence 官方报告 62

- 1 8 9 30 32 53 59 StoryScope: Investigating idiosyncrasies in AI fiction
https://arxiv.org/abs/2604.03136?utm_source=chatgpt.com
- 2 5 31 34 49 58 Flowith - Your AI Creation Workspace, with Knowledge
https://flowith.com/?utm_source=chatgpt.com
- 3 62 ● 人工智能-中国计算机学会
https://www.ccf.org.cn/Academic_Evaluation/AI/?utm_source=chatgpt.com
- 4 21 23 61 LoRA: Low-Rank Adaptation of Large Language Models
https://arxiv.org/abs/2106.09685?utm_source=chatgpt.com
- 6 Manus API - Manus Documentation
https://manus.im/docs/integrations/manus-api?utm_source=chatgpt.com
- 7 Flowith - Your AI Creation Workspace, with Knowledge
https://flowith.com/canvas?utm_source=chatgpt.com
- 10 Can AI writing be salvaged? Mitigating Idiosyncrasies and Improving Human-AI Alignment in the Writing Process through Edits
https://arxiv.org/abs/2409.14509?utm_source=chatgpt.com
- 11 33 Plan-and-Write: Towards Better Automatic Storytelling | Proceedings of the AAAI Conference on Artificial Intelligence
https://ojs.aaai.org/index.php/AAAI/article/view/4726?utm_source=chatgpt.com
- 12 13 22 60 GPT-4.1 Model | OpenAI API
https://platform.openai.com/docs/models/gpt-4.1?utm_source=chatgpt.com
- 14 Introducing Sonnet 4.6
https://www.anthropic.com/news/claude-sonnet-4-6?rd=1&utm_source=chatgpt.com
- 15 Gemini Models | Gemini API | Google AI for Developers
https://ai.google.dev/gemini-api/docs/models/gemini-v2?utm_source=chatgpt.com
- 16 43 Models & Pricing | DeepSeek API Docs
https://api-docs.deepseek.com/quick_start/pricing/?utm_source=chatgpt.com
- 17 GLM-5.1 - 智谱AI开放文档
https://docs.bigmodel.cn/cn/guide/models/text/glm-5.1?utm_source=chatgpt.com
- 18 Qwen
https://qwen.ai/blog?id=qwen3&utm_source=chatgpt.com
- 19 DeepSeek-V3 Technical Report
https://arxiv.org/abs/2412.19437?utm_source=chatgpt.com
- 20 BGE M3-Embedding: Multi-Lingual, Multi-Functionality, Multi-Granularity Text Embeddings Through Self-Knowledge Distillation
https://arxiv.org/abs/2402.03216?utm_source=chatgpt.com
- 24 Training language models to follow instructions with human feedback
https://arxiv.org/abs/2203.02155?utm_source=chatgpt.com
- 25 36 Direct Preference Optimization: Your Language Model is Secretly a Reward Model
https://arxiv.org/abs/2305.18290?utm_source=chatgpt.com
- 26 Paper page - CTRL: A Conditional Transformer Language Model for Controllable Generation
https://huggingface.co/papers/1909.05858?utm_source=chatgpt.com

- 27 Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks
https://arxiv.org/abs/2005.11401?utm_source=chatgpt.com
- 28 Psychology-guided Controllable Story Generation
https://arxiv.org/abs/2210.07493?utm_source=chatgpt.com
- 29 37 R2-Write: Reflection and Revision for Open-Ended Writing with Deep Reasoning
https://arxiv.org/abs/2604.03004?utm_source=chatgpt.com
- 35 55 Introduction - Manus API
<https://open.manus.im/docs/v2/introduction>
- 38 Welcome to SGLang - SGLang Documentation
https://docs.sglang.io/?utm_source=chatgpt.com
- 39 40 45 Introducing GPT-4.1 in the API | OpenAI
https://openai.com/index/gpt-4-1/?utm_source=chatgpt.com
- 41 Claude Sonnet \ Anthropic
https://www.anthropic.com/claude/sonnet?_bhlid=d2fee3999c74adae58c5710e9cf57b7a4c9297fc&utm_source=chatgpt.com
- 42 Gemini Developer API pricing | Gemini API | Google AI for Developers
https://ai.google.dev/gemini-api/docs/pricing?utm_source=chatgpt.com
- 44 ZHIPU AI OPEN PLATFORM
https://open.bigmodel.cn/pricing?utm_source=chatgpt.com
- 46 GPU pricing | Google Cloud
<https://cloud.google.com/products/compute/gpus-pricing?hl=en>
- 47 AWQ: Activation-aware Weight Quantization for LLM Compression and Acceleration
https://arxiv.org/abs/2306.00978?utm_source=chatgpt.com
- 48 Distilling Step-by-Step! Outperforming Larger Language Models with Less Training Data and Smaller Model Sizes
https://arxiv.org/abs/2305.02301?utm_source=chatgpt.com
- 50 QLoRA: Efficient Finetuning of Quantized LLMs
https://arxiv.org/abs/2305.14314?utm_source=chatgpt.com
- 51 56 Fabula: Building a Narrative Storytelling Sidekick with the Writers' Community
https://arxiv.org/abs/2606.14411?utm_source=chatgpt.com
- 52 MAUVE: Measuring the Gap Between Neural Text and Human Text using Divergence Frontiers
https://arxiv.org/abs/2102.01454?utm_source=chatgpt.com
- 54 BERTScore: Evaluating Text Generation with BERT
https://arxiv.org/abs/1904.09675?utm_source=chatgpt.com
- 57 四部门联合发布《人工智能生成合成内容标识办法》_中央网络安全和信息化委员会办公室
https://www.cac.gov.cn/2025-03/14/c_1743654685899683.htm?utm_source=chatgpt.com